

Stage2 可微 ICCD 技术总结

第二阶段阶段性训练与分场景评估总结

更新时间：2026-07-09

1. 本轮目标

本轮目标不是直接把所有信号类型一次性强行训练到最好，而是按稳定性逐步推进：

- 1. 先从较简单、较稳定的信号开始，例如线性 chirp、二次多项式 chirp、三次多项式 chirp。
- 2. 如果简单场景下 IF-Net + 可微 ICCD 层能够稳定重构，再扩展到全部类型。
- 3. 对全部类型做分场景评估，找出哪些类型已经满足第二阶段继续推进的需要，哪些类型还需要单独优化。
- 4. 对困难类型尝试专家模型或专门配置，判断是否能通过更长训练解决。

2. 已完成的代码工作

本轮在第二阶段代码中补充了分场景评估和多种训练配置：

- 新增 `src/stage2_iccd/eval_scenarios.py`，用于对指定 checkpoint 按信号类型分别评估。
- 新增 `configs/separated_frozen.yaml`，用于简单分离场景的课程训练。
- 新增 `configs/all_multiexpert.yaml`，用于多 IF-Net 专家候选输入的全类型训练实验。
- 新增 `configs/local_jump_frozen.yaml`，用于 `local_jump` 专门训练。
- 新增 `configs/sinusoidal_frozen.yaml`，用于 `sinusoidal_fm` 专门训练。
- 修改 `model.py` 中的候选 IF 混合器：
 - 原先是全局可学习平均，容易把不同专家输出的 IF 曲线直接平均成不存在的轨迹。
 - 现在增加基于 ICCD 初步重构残差的动态候选权重，让每个样本根据重构误差选择更合适的候选。
- 修改训练日志，记录候选权重均值和候选选择温度。

3. 训练路径与主要结果

3.1 简单分离场景训练

训练对象：linear、quadratic、cubic。

使用配置：`configs/separated_frozen.yaml`

训练后 checkpoint: `stage2_iccd/runs/separated_frozen/latest.pt`

分场景评估结果：

场景	重构 SNR / dB	IF MAE / Hz
linear	23.40	2.38
quadratic	23.02	2.47
cubic	21.64	3.55

场景	重构 SNR / dB	IF MAE / Hz
aggregate	22.69	2.80

结论：简单场景训练是稳定的。说明第二阶段的可微 ICCD 层、alpha 学习、候选 IF 权重和小型 IF refinement head 都能正常参与训练，并且没有出现明显梯度或重构不稳定问题。

3.2 从简单场景扩展到全部类型

使用 separated_frozen 作为初始化，继续训练全部类型。

训练后 checkpoint: stage2_iccd/runs/all_from_separated/latest.pt

这是目前最稳的通用第二阶段 checkpoint。

分场景评估结果：

场景	重构 SNR / dB	IF MAE / Hz	判断
linear	21.18	3.26	可接受
quadratic	21.76	2.40	较好
cubic	21.52	3.22	可接受
sinusoidal_fm	17.67	5.58	偏弱
crossing	19.97	3.03	可接受
near_parallel	23.35	1.71	最稳定
local_jump	16.17	6.70	明显偏弱
tangent_or_overlap	21.11	3.13	可接受
aggregate	20.34	3.63	总体可用

结论：全类型一起推进是可行的，但不是所有类型同步受益。当前通用模型对 linear、quadratic、cubic、crossing、near_parallel、tangent_or_overlap 的表现已经比较稳定；主要短板集中在 local_jump 和 sinusoidal_fm。

4. 困难类型的补充实验

4.1 sinusoidal_fm 专门模型

训练后 checkpoint: stage2_iccd/runs/sinusoidal_frozen/latest.pt

评估结果：

场景	重构 SNR / dB	IF MAE / Hz
sinusoidal_fm	20.28	4.05

相对通用模型：

- 通用模型：17.67 dB, 5.58 Hz
- sinusoidal 专门模型：20.28 dB, 4.05 Hz

结论：sinusoidal_fm 可以通过专门训练明显改善。后续可以保留通用模型，也可以在路由器足够稳定后为 sinusoidal_fm 使用专门分支。

4.2 local_jump 专门模型

训练后 checkpoint: stage2_iccd/runs/local_jump_frozen/latest.pt

评估结果：

场景	重构 SNR / dB	IF MAE / Hz
local_jump	15.15	8.34

相对通用模型：

- 通用模型：16.17 dB, 6.70 Hz
- local_jump 专门模型：15.15 dB, 8.34 Hz

结论：local_jump 不是简单换成 local_jump IF-Net checkpoint 或继续训练 ICCD 层就能解决。它的误差主要来自跳变位置和跳变前后 IF 段的结构没有被第二阶段显式建模。当前的 ICCD refinement head 更擅长连续、小幅、平滑修正，对突变点附近的非平滑 IF 变化表达能力不足。

5. 多专家候选混合实验

本轮尝试了多 IF-Net 专家候选输入，包括 balanced、polynomial、sinusoidal、local_jump 等多个第一阶段 checkpoint。

5.1 全局平均式候选混合

结果较差：

- validation 重构 SNR 约 13.45 dB
- validation IF MAE 约 14.40 Hz

主要原因：不同专家输出的 IF 曲线不一定是同一个物理分量的同一个候选。直接做全局可学习平均时，可能把几条合理曲线平均成一条不真实的中间曲线，尤其在 crossing、local_jump、相切或短时重合场景中更明显。

5.2 基于 ICCD 残差的动态候选混合

动态混合后，模型会根据每个候选 IF 的初步 ICCD 重构残差来给权重。

结果仍不适合作为主路径：

- aggregate 重构 SNR 约 16.54 dB
- aggregate IF MAE 约 11.45 Hz
- crossing 出现明显退化，重构 SNR 约 4.32 dB, IF MAE 约 30.43 Hz

原因：ICCD 残差本身并不总能区分“物理身份正确的 IF”和“短时间内也能解释能量但身份错误的 IF”。在 crossing 场景中，候选曲线可能局部重构误差不大，但分量身份已经交换，导致后续 ICCD 展开层沿错误轨迹分解。

结论：多专家不是不能用，但不能只靠残差选择。后续如果使用多专家，需要加入场景判别器或身份一致性约束，让路由器先判断信号结构，再决定使用哪个专家或怎样融合 top-k 候选。

6. 当前最佳使用建议

当前第二阶段最稳组合：

- 通用模型：stage2_iccd/runs/all_from_separated/latest.pt
- sinusoidal_fm 专门模型：stage2_iccd/runs/sinusoidal_frozen/latest.pt

建议：

1. 一般场景优先使用 all_from_separated。
2. 如果前端判别器较确定是 sinusoidal_fm，可以切换到 sinusoidal_frozen。
3. 暂时不要把 all_multiexpert_dynamic 作为主模型，因为它在 crossing 上不稳定。
4. local_jump 暂时继续使用通用模型，直到第二阶段加入显式跳变位置建模。

7. 对第二阶段任务的影响

第二阶段的核心目标是用可微 ICCD 展开层把第一阶段的 IF 初始估计转化为可重构、可反传、可联合优化的分量分解过程。

从当前结果看：

- 简单场景和多数连续 IF 场景已经能支撑第二阶段继续推进。
- crossing 当前通用模型表现可接受，但多专家路由会引入身份交换风险，因此后续必须保留 top-2 候选和身份一致性检查。
- local_jump 会影响第二阶段的端到端精修，因为跳变点附近 IF 误差会直接导致相位积分误差，进而影响 ICCD 字典构造和分量重构。
- sinusoidal_fm 需要专门路由或更强的周期性 IF refinement，但问题比 local_jump 更容易通过专门模型缓解。

8. 下一步优化方向

优先级建议如下：

1. 为 local_jump 增加跳变位置辅助输入或辅助头。
 - 第一阶段已经有跳变事件定位思路，但第二阶段目前没有显式使用它。
 - 应把 jump position、jump confidence 或 jump mask 输入到 refinement head。
 - refinement head 在跳变点附近允许更大、更局部的 IF 修正。
2. 把 ICCD 展开层改成局部/分段式 IF refinement。
 - 对 local_jump，不能只用全局平滑修正。
 - 可以在跳变点前后分别建模 IF 曲线或分别设置正则强度。
3. 为 crossing 加身份一致性约束。
 - 保留 top-2 候选。
 - 在时间轴上限制分量身份频繁交换。
 - 训练损失中加入轨迹连续性或最优匹配约束。
4. 重新设计多专家路由器。
 - 不建议只用 ICCD 残差。

- 应结合信号类型判别器、候选置信度、身份一致性和局部重构误差。

5. 在通用模型稳定后，再逐步解冻 IF-Net。

- 目前仍建议先固定第一阶段 IF-Net，只训练 alpha、候选权重和 refinement head。
- 等 local_jump 和 crossing 的第二阶段机制补足后，再做端到端联合训练。

9. 当前是否可以继续第二阶段

可以继续第二阶段，但需要分层推进：

- 对 linear、quadratic、cubic、near_parallel、tangent_or_overlap、crossing：可以继续使用当前通用模型推进可微 ICCD 展开层和端到端训练框架。
- 对 sinusoidal_fm：可以使用专门模型作为临时分支，并继续优化路由。
- 对 local_jump：不建议直接进入大规模联合训练，应先补充跳变位置辅助头或分段式 refinement，否则端到端训练可能把误差传回 IF-Net，造成不稳定的错误修正。

因此，当前判断是：第二阶段框架已经成立，通用模型基本可用；但 local_jump 需要作为下一轮重点结构优化，而不是只依赖更长训练。

10. 2026-07-08 补充：先打牢简单多分量

根据“先专攻单分量与简单多分量，交叉、跳变等困难类型后续再攻克”的路线，本轮先没有把 crossing、local_jump 等困难类型继续混入训练，而是集中处理 linear、quadratic、cubic 这三类简单分离多分量信号。

10.1 为什么暂时没有直接做真正单分量

当前第二阶段使用的冻结 IF-Net checkpoint 是按 2 分量输出训练的。如果直接把真实 1 分量样本喂给第二阶段，第二条不存在的分量会带来两个问题：

- component loss 可以用零分量匹配处理，但 IF loss 仍会惩罚第二条“并不存在”的 IF；
- 可微 ICCD 层会尝试解释不存在的第二分量，可能把噪声当作弱分量重构。

因此，真正单分量需要先加入 inactive component mask 或 active-component loss mask。为了保证优化路径干净，本轮先做“简单、分离、2 分量”。

10.2 simple_multicomponent_long

配置：configs/simple_multicomponent_long.yaml

训练路径：

- 从 stage2_iccd/runs/separated_frozen/latest.pt 续训；
- 只使用 linear、quadratic、cubic；
- 训练噪声先限制为 white + colored；
- SNR 范围设为 4 dB 到 28 dB；
- 继续训练 800 步。

训练后 checkpoint：stage2_iccd/runs/simple_multicomponent_long/latest.pt

与原 separated_frozen 在同一 easy 条件下比较：

模型	aggregate SNR / dB	aggregate IF MAE / Hz	smooth
separated_frozen	25.62	2.20	9.21
simple_multicomponent_long	25.93	1.64	2.59

分场景结果：

场景	SNR / dB	IF MAE / Hz
linear	26.74	1.30
quadratic	25.94	1.58
cubic	25.12	2.06
aggregate	25.93	1.64

结论：这一步达到了较好的效果。IF 精度明显提升，曲线二阶平滑度明显降低，说明第二阶段 refinement head 没有只是追求重构误差，而是把 IF 轨迹也修得更稳。

10.3 鲁棒条件复测

在更复杂条件下评估：

- SNR 范围：-2 dB 到 24 dB；
- 噪声：white 0.55、colored 0.25、impulsive 0.10、trend 0.10。

模型	aggregate SNR / dB	aggregate IF MAE / Hz	smooth
separated_frozen	22.94	2.91	13.68
simple_multicomponent_long	22.86	2.55	4.46

结论：鲁棒条件下重构 SNR 基本持平，IF MAE 和 smoothness 仍然更好。因此 simple_multicomponent_long 可以作为当前简单多分量阶段的最佳模型。

10.4 simple_multicomponent_robust 尝试

配置：configs/simple_multicomponent_robust.yaml

训练路径：

- 从 simple_multicomponent_long/latest.pt 续训；
- 训练时加入 impulsive 和 trend 噪声；
- 继续训练 600 步。

结果：

评估条件	SNR / dB	IF MAE / Hz	smooth
easy	25.53	1.74	2.21
robust	22.48	2.58	3.23

结论：鲁棒续训没有超过 simple_multicomponent_long。它让 IF 曲线更平滑，但重构 SNR 略降，且 robust IF MAE 没有实质改善。因此它目前只作为诊断实验保留，不作为第一步最佳 checkpoint。

10.5 当前第一步判断

当前简单多分量阶段可以视为初步达标：

- easy 条件 aggregate IF MAE 已降到约 1.64 Hz；
- robust 条件 aggregate IF MAE 约 2.55 Hz；
- linear/quadratic/cubic 都没有明显失控；
- 可微 ICCD 层的 alpha、候选权重和 IF refinement head 都能稳定训练。

下一步不建议立刻攻 local_jump。更稳的顺序是：

1. 增加 active-component mask，补真正单分量训练和评估；
2. 在简单多分量基础上加入 near_parallel 或更小间隔的非交叉多分量；
3. 简单和近邻场景都稳定后，再进入 crossing；
4. 最后单独攻 local_jump，并加入跳变位置辅助头。

11. 2026-07-08 补充：单分量与单/多分量合并尝试

11.1 active-component mask

为了正确处理真正单分量，代码中新增了 active-component mask：

- 仿真器现在可以通过 active_components 指定真实活跃分量数；
- inactive component 的幅值设为 0；
- component/reconstruction loss 仍约束模型不要重构不存在的分量；
- IF loss 只在 active component 上计算，避免用不存在的第二条 IF 污染训练。

这一步是必要的。否则单分量训练会把“第二条不存在的 IF”当作真实目标，造成错误优化。

11.2 单分量专用模型

配置：configs/simple_single_component.yaml

训练路径：

- 从 simple_multicomponent_long/latest.pt 续训；
- 只使用 linear、quadratic、cubic；
- active_components: 1；
- 训练 500 步。

checkpoint: stage2_iccd/runs/simple_single_component/latest.pt

单分量 easy 条件评估：

场景	SNR / dB	IF MAE / Hz	component L1
linear	26.64	0.65	0.029
quadratic	27.71	0.69	0.025
cubic	26.83	0.73	0.028
aggregate	27.06	0.69	0.028

单分量 robust 条件评估：

场景	SNR / dB	IF MAE / Hz	component L1
linear	23.35	0.73	0.041
quadratic	23.87	0.78	0.039
cubic	23.71	0.82	0.040
aggregate	23.64	0.78	0.040

结论：单分量专用模型效果很好，说明 active-component mask 是有效的。

11.3 单分量模型不能直接处理双分量

把 simple_single_component/latest.pt 放到 2 active components 的 easy 条件下评估：

条件	SNR / dB	IF MAE / Hz	component L1
2 分量 easy	7.57	7.07	0.223

结论：单分量模型非常专用，不能直接用于双分量。它会倾向于只解释一个主分量，导致另一个真实分量重构失败。

11.4 双分量模型处理单分量的表现

把 simple_multicomponent_long/latest.pt 放到 1 active component 的 easy 条件下评估：

条件	SNR / dB	IF MAE / Hz	component L1
1 分量 easy	28.49	1.32	0.189

结论：双分量模型对单分量的重构 SNR 和 IF 还可以，但 component L1 很高，说明它会把单个真实分量拆到两个输出槽位中。这对后续可解释分量分解是不利的。

11.5 mixed-active 统一模型尝试

配置：configs/simple_active_mixed.yaml

训练路径：

- 从 simple_multicomponent_long/latest.pt 续训；
- 训练样本中 45% 为单分量，55% 为双分量；
- 训练 700 步。

评估结果：

条件	SNR / dB	IF MAE / Hz	component L1
1 分量 easy	27.58	1.53	0.063
2 分量 easy	23.71	2.96	0.061
mixed robust	22.71	2.70	0.070

结论：mixed-active 统一模型没有超过专用模型组合。它比单分量专用模型差，也比双分量专用模型差，说明单/多分量在当前第二阶段结构中存在明显任务冲突。

11.6 当前最稳组合

当前不建议强行用一个模型同时处理单分量和双分量。最稳组合是：

- 单分量: stage2_iccd/runs/simple_single_component/latest.pt
- 简单双分量: stage2_iccd/runs/simple_multicomponent_long/latest.pt

进入下一步之前, 建议先加 active-component 判别器或能量型路由器:

- 若判定为 1 active component, 走单分量专用模型;
- 若判定为 2 active components, 走简单双分量模型;
- 如果判别置信度低, 保留 top-2 active-count 候选, 进入第二阶段时同时输出置信度。

因此, 当前简单单分量和简单双分量都已经有了可用模型, 但还需要一个轻量 active-count 路由器, 才能形成完整稳定的第一层处理流程。

12. 2026-07-08 补充: active-count 路由器与 near_parallel 纳入

在完成单分量专用模型和简单双分量专用模型之后, 本轮继续补上了一个轻量 active-count 路由器。它的任务不是直接预测完整 IF, 而是先判断输入信号更像 1 个活跃分量还是 2 个活跃分量, 然后把样本送到对应的第二阶段模型:

- 1 active component: 使用 stage2_iccd/runs/simple_single_component/latest.pt;
- 2 active components: 使用 stage2_iccd/runs/simple_multicomponent_long/latest.pt。

这样做的原因是, 前面的实验已经说明 “一个统一模型同时处理单分量和双分量” 会出现明显任务冲突。单分量模型很擅长单分量, 但不能直接处理双分量; 双分量模型能重构单分量, 却容易把一个真实分量拆到两个输出槽位里。因此先做 active-count 判别, 再走专门模型, 比强行用一个模型覆盖所有情况更稳。

12.1 新增代码

本轮新增了以下代码和配置:

- src/stage2_iccd/active_count.py: active-count 分类网络。输入来自多尺度 STFT 图和辅助统计特征, 输出 active_1 / active_2 两类概率、置信度和 margin;
- src/stage2_iccd/train_active_count.py: active-count 路由器训练脚本;
- src/stage2_iccd/eval_active_count.py: active-count 单独评估脚本;
- src/stage2_iccd/eval_active_routed_stage2.py: 把 active-count 路由器接到单分量/双分量 Stage2 模型后的端到端评估脚本;
- configs/active_count_simple.yaml: 只包含 linear、quadratic、cubic 的初始路由器配置;
- configs/active_count_simple_near_parallel.yaml: 在简单场景基础上加入 near_parallel 的路由器配置。

12.2 初始 active-count 路由器

先用 active_count_simple.yaml 训练, 只覆盖 linear、quadratic、cubic 的 1/2 active component 判别。

在简单 easy 条件下:

评估范围	accuracy	active_1 accuracy	active_2 accuracy
linear/quadratic/cubic	99.1%	99.7%	98.5%

在 robust 条件下:

评估范围	accuracy	active_1 accuracy	active_2 accuracy
linear/quadratic/cubic	97.3%	98.1%	96.5%

接到 Stage2 后，linear/quadratic/cubic 的 routed 结果为：

条件	route accuracy	IF MAE / Hz	重构 SNR / dB
easy	99.4%	1.30	26.01
robust	97.7%	1.85	23.09

结论：只看简单场景时，active-count 路由器已经足够稳定，可以把单分量和双分量模型组合起来使用。

12.3 near_parallel 的问题与修正

继续把同一个 active-count 路由器放到 near_parallel 上评估，发现准确率只有约 90%：

条件	accuracy	active_1 accuracy	active_2 accuracy
near_parallel easy	90.3%	85.6%	95.0%
near_parallel robust	90.2%	88.9%	91.6%

这个结果说明 near_parallel 的主要问题不在第二阶段 ICCD 重构本身，而在“路由器没有见过这类结构”。near_parallel 的时频图中，两条 IF 长时间接近并近似平行，能量分布容易被误判成一个宽一些的单分量脊线；反过来，某些单分量的缓慢弯曲也可能被误判成两个贴近分量。因此如果 active-count 路由器只用普通 separated linear/quadratic/cubic 训练，面对 near_parallel 会不稳定。

为了修正这个问题，本轮训练了 active_count_simple_near_parallel.yaml，把 near_parallel 一并加入 active-count 训练。

修正后，near_parallel 路由准确率明显提高：

条件	accuracy	active_1 accuracy	active_2 accuracy
near_parallel easy	99.1%	100.0%	98.3%
near_parallel robust	97.6%	99.8%	95.3%

同时重新检查 linear/quadratic/cubic，没有发生严重遗忘：

条件	accuracy	active_1 accuracy	active_2 accuracy
simple easy	98.6%	100.0%	97.2%
simple robust	96.8%	100.0%	93.7%

这里要注意一个小代价：加入 near_parallel 后，强噪声下简单双分量的路由准确率从约 96.5% 降到约 93.7%。这说明路由器容量和训练分布仍然有限，但端到端 Stage2 指标仍然可用。

12.4 新路由器接入 Stage2 后的结果

使用新路由器 active_count_simple_near_parallel/latest.pt，并接入：

- 单分量模型：simple_single_component/latest.pt；
- 双分量模型：simple_multicomponent_long/latest.pt。

在 linear、quadratic、cubic、near_parallel 四类上做 routed Stage2 评估，结果如下：

条件	route accuracy	IF MAE / Hz	重构 SNR / dB	component L1
easy	98.8%	1.18	26.21	0.039
robust	97.3%	1.64	23.42	0.050

分场景看，单分量 IF MAE 基本稳定在 0.62-0.86 Hz；双分量中 near_parallel 的 IF MAE 为 easy 1.30 Hz、robust 1.66 Hz，说明第二阶段 ICCD 对 near_parallel 本身并不弱。当前 near_parallel 的主要风险已经从“重构能力不足”转移到“路由器是否足够稳定”。

12.5 当前判断

到目前为止，第一批可继续推进的第二阶段场景包括：

- 单分量 linear / quadratic / cubic；
- 简单双分量 linear / quadratic / cubic；
- near_parallel。

这些场景已经满足继续推进的基本门槛：路由准确率在 easy/robust 条件下都接近或超过 97%，端到端 IF MAE 在 1-2 Hz 左右，重构 SNR 大约 23-26 dB。

暂时不建议直接把 crossing 和 local_jump 加进同一个训练任务。原因是：

- crossing 的主要风险是分量身份交换，不能只靠 active-count 路由解决；
- local_jump 的主要风险是跳变位置定位和跳变点附近的分段 IF 修正，需要显式 jump head 或 jump mask；
- sinusoidal_fm 比 crossing/local_jump 更适合作为下一步，因为它仍属于连续 IF，只是周期性调制更强，适合作为从简单连续场景到困难场景之间的过渡。

12.6 下一步优化顺序

下一轮建议按下面顺序推进：

1. 把 sinusoidal_fm 纳入当前 active-count + routed Stage2 流程，先看路由是否稳定，再看 Stage2 是否需要专门分支；
2. 如果 sinusoidal_fm 的路由稳定但 IF MAE 偏高，优先训练 sinusoidal_fm 的 Stage2 分支，而不是马上解冻 IF-Net；
3. 再进入 crossing，重点加入身份一致性约束和 top-2 候选保留；
4. 最后集中处理 local_jump，加入跳变位置辅助头、jump mask 或分段 refinement。

因此，本轮结论是：简单单/双分量和 near_parallel 的 Stage2 路由框架已经基本打通，可以继续往 sinusoidal_fm 扩展；但 crossing/local_jump 仍应作为后续专项攻克对象。

13. 2026-07-09 补充：多项式双分量尾部误差专项优化

在重新生成“旧模型 vs 新模型”的可视化图之后，可以看到当前第二阶段已经能让多数简单单分量、简单双分量和 near_parallel 的曲线更接近真实 IF。但有一个比较明显的弱点：quadratic active=2 这类双分量多项式信号仍然存在尾部误差。也就是说，平均效果已经不错，但某些样本的局部弯曲、端点区域或两分量接近区域会出现偏离。

这类问题和 crossing/local_jump 不完全一样。crossing 的核心问题是身份交换，local_jump 的核心问题是跳变点定位；而 quadratic/cubic active=2 的主要问题是连续曲线的弯曲形状和双分量间距同时变化，第二阶段如果只按普通 separated 双分量训练，容易学到比较平滑、保守的修正，无法完全覆盖多项式尾部样本。

13.1 本轮新增的诊断工具

本轮新增了一个样本级 checkpoint 对比脚本：

- `stage2_iccd/scripts/compare_stage2_checkpoints.py`

它的作用是让两个 Stage2 checkpoint 在同一批仿真样本上逐个比较，而不是只看一次汇总平均值。脚本会输出：

- 两个 checkpoint 的 IF MAE 均值、中位数、p90、p95；
- 重构 SNR 均值；
- 新 checkpoint 相比旧 checkpoint 的逐样本胜率；
- `comparison.json` 和 `comparison.csv`，方便后续定位“哪些样本被改善，哪些样本被恶化”。

这个脚本很重要，因为当前任务不能只看平均值。如果某个模型平均值略好，但 p90/p95 或其他场景明显变差，它就不适合作为默认模型。

13.2 多项式专项双分量模型

首先训练了 `poly_multicomponent_refine`，配置文件为：

- `stage2_iccd/configs/poly_multicomponent_refine.yaml`

这个模型从当前简单双分量稳定 checkpoint 继续训练：

- 初始化 checkpoint: `stage2_iccd/runs/simple_multicomponent_long/latest.pt`；
- 固定为 2 active components；
- 加大 quadratic 和 cubic 的采样权重；
- 保留少量 linear 和 near_parallel，避免模型完全只记住多项式样本；
- 适当放宽 IF refinement 幅度，让模型能修正更大的局部偏差。

训练后的分场景评估如下。

条件	linear IF MAE / Hz	quadratic IF MAE / Hz	cubic IF MAE / Hz	near_parallel IF MAE / Hz	平均 IF MAE / Hz	SNR / dB
easy	1.01	1.70	2.10	1.03	1.46	25.76
robust	3.99	2.47	3.50	1.36	2.83	22.58

从这个表可以看出，`poly_multicomponent_refine` 对多项式双分量确实有帮助，但它不是一个适合直接替换默认模型的结果。原因是 robust 条件下 linear 明显退化，IF MAE 到了约 3.99 Hz。这说明它学到了更偏向弯曲多项式的修正策略，对线性双分量不够稳。

为了更公平地判断它是否真的改善 quadratic active=2，又做了 160 个样本的逐样本对比。对比对象是当前默认双分量模型 `simple_multicomponent_long`。

条件	默认模型 mean / Hz	多项式专项 mean / Hz	默认模型 p95 / Hz	多项式专项 p95 / Hz	专项模型胜率
quadratic easy	1.60	1.57	4.89	4.72	60.0%
quadratic robust	2.37	2.32	8.84	8.65	65.6%

这个结果说明：多项式专项模型确实能略微降低 quadratic active=2 的平均误差和 p95 误差，而且超过一半样本会变好。但改善幅度还不够大，p90 在 robust 条件下甚至有轻微变差。因此它目前更适合作为“诊断模型”或后续 hard-sample mining 的起点，而不是默认模型。

13.3 均衡双分量微调尝试

为了避免多项式专项模型牺牲 linear，本轮又训练了一个更均衡的模型：

- stage2_iccd/configs/balanced_multicomponent_refine.yaml

它仍然从 simple_multicomponent_long/latest.pt 继续训练，但不再过度偏向 quadratic/cubic，而是在 linear、quadratic、cubic、near_parallel 之间做相对温和的采样平衡。

评估结果如下。

条件	linear IF MAE / Hz	quadratic IF MAE / Hz	cubic IF MAE / Hz	near_parallel IF MAE / Hz	平均 IF MAE / Hz	SNR / dB
easy	1.44	1.87	1.89	1.15	1.59	25.82
robust	2.85	3.22	3.13	1.80	2.75	22.58

这个结果没有超过当前默认双分量模型。它对 easy 条件下的 cubic 有一点帮助，但 linear、quadratic、near_parallel 和 robust 条件整体变差。因此 balanced_multicomponent_refine 也不应作为默认模型。

13.4 当前采用的模型选择

本轮优化后的结论是：目前最稳的默认组合仍然保持不变。

- 单分量: stage2_iccd/runs/simple_single_component/latest.pt
- 简单双分量与 near_parallel: stage2_iccd/runs/simple_multicomponent_long/latest.pt
- active-count 路由器: stage2_iccd/runs/active_count_simple_near_parallel/latest.pt

新增的两个模型不删除，但暂时作为诊断和后续研究材料保留：

- stage2_iccd/runs/poly_multicomponent_refine/latest.pt: 多项式双分量专项模型，能轻微改善 quadratic 尾部，但会损害 robust linear;
- stage2_iccd/runs/balanced_multicomponent_refine/latest.pt: 均衡微调模型，没有超过默认双分量模型。

13.5 为什么继续盲目训练不一定有效

这轮实验说明，当前问题不只是“训练不够久”。如果简单延长训练或提高某一类样本权重，模型会在某些样本上改善，但容易把别的场景拉坏。根本原因可能有三点：

1. Stage2 的 IF refinement head 仍然比较轻量，面对二次/三次多项式的局部曲率变化时，表达能力有限；
2. Stage1 提供的 top-k 候选如果在困难样本里已经偏离真实 IF，Stage2 只能在有限范围内修正，不能凭空恢复完全正确的分量形状；
3. 当前 active-count 路由器只能判断 1/2 active components，不能区分 linear、quadratic、cubic 这样的多项式子类型，因此不能安全地把多项式专项模型只分配给真正需要它的样本。

因此，下一步更合理的优化方向不是直接替换默认模型，而是做“质量感知”的分支选择：

- 给 Stage2 增加候选置信度或重构残差门控；
- 对 quadratic/cubic active=2 的高误差样本做 hard-sample mining；
- 训练一个轻量 subtype / quality gate，用来判断样本是否需要走多项式专项分支；
- 继续保留当前默认双分量模型作为基线，任何新模型必须同时比较 mean、p90、p95 和跨场景退化情况。

13.6 对进入下一步的影响

这轮结果不会阻止进入后续第二阶段工作。原因是第二阶段的目标不是让初始 IF 完全贴合真实脊线，而是提供一个足够可靠的初始估计，让可微 ICCD 展开层能够稳定重构并反向微调。当前单分量、简单双分量和 near_parallel 已经满足这个要求。

但对于困难多分量多项式样本，需要注意：

- 如果只是做重构，当前默认模型已经基本可用；
- 如果要求 IF 曲线在图上非常贴近真实曲线，quadratic/cubic active=2 的尾部样本仍需要继续优化；
- 如果后续进入 crossing/local_jump，不能把这类误差简单归因于 ICCD 层，而要同时检查 Stage1 候选质量、身份一致性、跳变位置辅助头和路由稳定性。

所以当前阶段的建议是：默认流程继续使用稳定组合；多项式专项模型作为备选诊断分支保留；下一步优先做候选质量/置信度门控和 hard-sample mining，再继续扩展到 sinusoidal_fm、crossing 和 local_jump。

14. 2026-07-09 补充：默认双分量与多项式专项分支的质量门控

上一节说明，多项式专项模型不能直接替换默认双分量模型，因为它在某些样本上改善 IF，但也可能让其他样本变差。为了继续优化，本轮没有继续盲目加训练轮数，而是做了一个更接近实际部署的问题：如果系统同时保留默认双分量分支和多项式专项分支，能不能根据模型自己的输出质量，自动选择更可信的一支？

14.1 新增脚本

本轮新增两个诊断脚本：

- stage2_iccd/scripts/evaluate_stage2_quality_gate.py
- stage2_iccd/scripts/sweep_stage2_quality_gate.py

第一个脚本会在同一批样本上同时运行：

- 默认双分量模型：simple_multicomponent_long/latest.pt；
- 多项式专项模型：poly_multicomponent_refine/latest.pt。

然后它记录四种结果：

- default：永远使用默认双分量模型；
- specialist：永远使用多项式专项模型；
- gated：根据无监督质量分数在两个分支中选择；
- oracle：根据真实 IF 误差选择更好分支，只作为理论上限，实际部署不能使用。

无监督质量分数主要来自“重构后和观测信号的残差”，并加入 IF 修正量和平滑度惩罚。它的意义是：真实部署时拿不到真实 IF，但可以看到当前分支重构出来的信号是否贴近输入信号，以及 IF 修正是否过大、是否过度抖动。

第二个脚本会在保存下来的 CSV 上扫描不同的 penalty 和 margin，不重新跑模型，用来判断这种简单无监督门控的上限。

14.2 初始保守门控的结果

先使用比较保守的设置：

- `delta_penalty=0.015`
- `smooth_penalty=0.000002`
- `score_margin=0.05`

这个设置要求专项分支的质量分数明显高于默认分支，才切换到专项分支。

在 easy 条件下，结果为：

选择方式	IF MAE mean / Hz	IF MAE p95 / Hz	使用专项分支比例	oracle 匹配率
default	1.617	3.783	0.0%	38.1%
specialist	1.566	3.861	100.0%	61.9%
gated	1.611	3.800	18.1%	39.4%
oracle	1.515	3.783	61.9%	100.0%

在 robust 条件下，结果为：

选择方式	IF MAE mean / Hz	IF MAE p95 / Hz	使用专项分支比例	oracle 匹配率
default	2.236	8.283	0.0%	28.1%
specialist	2.141	8.139	100.0%	71.9%
gated	2.225	8.283	13.1%	32.5%
oracle	2.109	8.139	71.9%	100.0%

这个结果说明，保守门控太保守了。它只在 13%-18% 的样本上使用专项分支，而 oracle 显示实际上约 62%-72% 的样本使用专项分支会更好。因此，仅靠“专项分支必须明显更好”这个规则，会错过大部分可改善样本。

14.3 离线 sweep 后的较优门控

继续对质量分数参数做离线 sweep，合并 easy 和 robust 共 640 个样本，得到一个更合理的门控倾向：

- `delta_penalty=0.03`
- `smooth_penalty=0.0`
- `margin=-0.04`

这个设置的含义是：默认双分量模型作为兜底分支，多项式专项分支作为更积极的候选；只要专项分支没有明显比默认分支差，就优先使用专项分支。

合并 easy + robust 的结果如下。

选择方式	IF MAE mean / Hz	IF MAE p90 / Hz	IF MAE p95 / Hz	使用专项分支比例	oracle 匹配率
default	1.927	2.516	6.695	0.0%	33.1%
specialist	1.853	2.358	6.623	100.0%	66.9%
gated sweep-best	1.847	2.322	6.615	89.7%	70.0%
oracle	1.812	2.322	6.615	66.9%	100.0%

这个结果比保守门控更有价值。它说明“默认 + 专项 + 质量门控”确实可以比单独使用默认模型更好，也略好于永远使用专项模型。但提升幅度仍然不大，说明当前的无监督质量特征还比较粗糙。

14.4 当前结论

质量门控给出了三个重要判断：

1. 多项式专项分支不是无用分支。很多样本上它比默认双分量模型更好，尤其在 robust 条件下，oracle 使用专项分支的比例达到约 72%。
2. 单纯看重构残差不够可靠。重构更贴近观测信号，不一定代表 IF 曲线更贴近真实 IF，因为噪声、分量交换和局部过拟合都会影响残差。
3. 当前最实用的门控策略不是“只有专项明显更好才切换”，而是“专项优先，默认兜底”。这说明多项式专项训练方向是有用的，但还需要更强的质量判别特征。

因此，下一步不建议直接把 `poly_multicomponent_refine` 替换为默认双分量模型，而是建议继续做一个真正的 supervised quality head。这个 quality head 可以用仿真数据训练，输入包括：

- 两个分支的观测重构残差；
- IF refinement 的修正幅度；
- IF 曲线平滑度和局部曲率；
- 两个候选 IF 之间的差异；
- Stage1 候选置信度和 top-2 间距；
- active-count 路由器置信度。

训练目标不是预测真实场景类型，而是预测“哪个分支的 IF 误差更小”或“当前样本是否属于高风险尾部样本”。这样比手工门控更贴近最终任务。

14.5 对后续路线的影响

当前默认流程仍保持：

- active-count 路由器先判断 1/2 active components；
- 单分量走 `simple_single_component`；
- 简单双分量和 `near_parallel` 走 `simple_multicomponent_long`；
- 多项式专项分支暂时不作为默认替换，而作为候选分支和 hard-sample mining 工具。

但从这一轮开始，后续优化方向已经从“继续训练一个更大的统一模型”转为“带质量感知的多分支选择”。这和后续处理 crossing/local_jump 的思路是一致的：困难样本不一定靠一个模型硬吃掉，而是先保留多个候选，再用置信度、身份一致性、跳变位置或重构质量来决定如何进入可微 ICCD 展开层。

因此，下一步建议优先实现 supervised quality head，并把它接到 routed Stage2 评估中。只有当 quality head 能稳定超过手工门控和永远使用专项分支，才把多项式专项分支纳入默认推理流程。

15. 2026-07-09 补充：按 P0 优先级落地的第一轮优化

本轮按照“先补关键信息通道和质量判断，再继续大改结构”的原则推进。由于当前 Stage2 的主干已经能稳定做重构，改动重点没有放在重新训练一个更大的网络，而是放在四个更靠近问题根源的位置：

1. 用监督式质量选择头替代纯手工门控；
2. 在 component loss 中显式处理 active / inactive 分量，减少单分量泄漏；
3. 给 Stage2 refinement head 预留 jump_mask 或 jump_prob 条件输入；
4. 在质量选择头训练中加入类别均衡和难例权重，避免选择器塌缩成“永远选某一个分支”。

15.1 监督式 Stage2 质量选择头

新增代码：

- stage2_iccd/src/stage2_iccd/quality_selector.py
- stage2_iccd/scripts/train_stage2_quality_selector.py
- stage2_iccd/scripts/eval_stage2_quality_selector.py

这个质量选择头的目标不是判断信号类型，而是判断“默认双分量分支”和“多项式专项分支”哪一个在当前样本上更可靠。训练标签由仿真数据自动生成：同一个样本同时经过两个 Stage2 分支，然后计算它们各自相对真实 IF 的 MAE，误差更小的分支作为监督标签。

输入特征没有使用真实 IF，因此未来推理时也能获得。当前使用的特征包括：

- 默认分支和专项分支的重构残差；
- 两个分支重构残差的差值与比例；
- 两个分支 refined IF 的差异统计量；
- IF 曲线的范围、斜率、平滑度和曲率；
- 候选权重熵，用来粗略表示候选 IF 的不确定性；
- 两个分支输出之间的整体偏离程度。

第一版直接训练时出现了一个问题：选择器倾向于永远选择多项式专项分支。独立评估结果如下：

选择方式	IF MAE mean / Hz	IF MAE p90 / Hz	IF MAE p95 / Hz	使用专项分支比例
default	2.294	3.997	9.296	0.0%
specialist	2.218	3.907	9.288	100.0%
selected	2.218	3.907	9.288	100.0%
oracle	2.175	3.830	9.158	66.3%

这说明监督标签本身不是问题，问题在于标签分布和分支差异都偏向专项分支，普通交叉熵很容易学成“只选专项”。因此我又加入了两项修正：

- 类别均衡：在一个 batch 内自动提高少数类标签的权重；
- margin 加权：两个分支 MAE 差距越大的样本权重越高，差距很小的样本权重降低。

平衡训练后的 best.pt 独立评估如下：

选择方式	IF MAE mean / Hz	IF MAE p90 / Hz	IF MAE p95 / Hz	使用专项分支比例	选择准确率
default	2.294	3.997	9.296	0.0%	-
specialist	2.218	3.907	9.288	100.0%	-
selected	2.221	3.907	9.288	79.6%	65.3%
oracle	2.175	3.830	9.158	66.3%	100.0%

这个结果比第一版健康，因为它不再永远选择同一个分支，并且 near_parallel 场景下 selected 的均值略好于 specialist。但从整体均值看，它仍然没有稳定超过“永远使用专项分支”。因此当前结论是：监督式 quality head 的代码路径已经打通，可以作为诊断和后续融合基础；但它暂时不应该替代默认推理策略。

15.2 active-component loss 与单分量泄漏

原来的 Stage2 已经在 IF loss 中使用了 active mask，也就是说真实不存在的分量不会强迫 IF 贴近某条伪曲线。但 component reconstruction loss 之前没有充分利用 active mask，这会带来一个隐患：当输入只有一个真实分量时，双分量模型可能把这个真实分量拆到两个输出槽里，看起来总重构还不错，但分量解释是错的。

本轮在 stage2_iccd/src/stage2_iccd/losses.py 中新增了：

- active_component_permutation_mse
- active_component_permutation_l1

它们先根据 active mask 做分量匹配，只对真实活跃分量计算主要匹配误差；同时对未匹配的 inactive 输出槽增加能量惩罚。这样模型不能再通过“多生成一条弱分量”来逃避单分量约束。

短训练探针已经验证新增指标可以正常进入训练日志：

指标	探针结果
if_mae_hz	1.109 Hz
rec_snr_db	28.48 dB
component_mse	0.0619
inactive_component_mse	0.0546

这只是 smoke 级验证，说明代码路径正常，不等价于已经把单分量泄漏彻底压到目标值以下。后续需要做更长训练，并单独统计 single active 输入下的 inactive component energy。

15.3 jump 条件输入接口

针对 local_jump，本轮先没有直接重训一个大模型，而是在 Stage2ICCDModel 和 IFRefinementHead 中加入了条件输入接口：

- Stage2ModelConfig.refine_extra_channels
- Stage2ICCDModel.forward(..., refinement_extra=...)
- IFRefinementHead.forward(..., extra=...)

这样后续可以把 Stage1 的 jump_mask、jump_prob 或 jump_center 辅助输出拼到 refinement head 的输入里。默认配置仍然是 refine_extra_channels=0，因此旧 checkpoint 不受影响。

这一点目前属于“结构预留”，还不是完整 local_jump 优化。真正让它产生收益，还需要两步：

1. 在 Stage1 输出中稳定导出每个候选 IF 对应的 jump probability 或 jump center；
2. 训练 Stage2 local_jump 专项模型，让 refinement head 学会在 jump 区域放宽平滑约束，在非 jump 区域保持强正则。

15.4 当前验证结果与是否进入下一步

本轮代码级验证均通过：

- compileall 通过；
- stage2_iccd.smoke_test 通过，ICCD 的 alpha、候选权重和 refinement head 梯度正常；
- simple_active_mixed 短训练通过，并产生 inactive_component_mse；
- supervised quality selector 能训练、保存、加载和独立评估。

但从任务效果看，还不能把 supervised quality selector 设为默认策略。原因很清楚：它虽然避免了完全塌缩，但整体 IF MAE 还没有稳定超过永远使用多项式专项分支。也就是说，P0 里的“监督式质量选择头”已经完成工程闭环，但还没有达到“默认部署”的效果闭环。

下一步更合理的优化顺序是：

1. 先扩大 quality selector 的特征，加入 Stage1 top-2 置信度、active-count 置信度、分支间身份一致性和局部曲率突变特征；
2. 对 active-component loss 做更长训练，单独评估单分量输入下的 inactive component energy；
3. 接入 Stage1 的 jump auxiliary 输出，开始训练 jump_mask 条件化的 local_jump refinement；
4. 等 quality selector 能稳定超过 specialist 或至少稳定降低 p95，再把它接入默认 routed Stage2；
5. 最后再推进相位通道或多专家软融合，因为这两项会牵动 Stage1/Stage2 输入结构，改动范围更大。